Projekt M.I.A

Dokumentace maturitního projektu

Michal Brus

Květen 2024

Obsah

1 Úvod **4**

1.1 Co je Projekt M.I.A? . . . 4

1.2 Vznik a Cíl Projektu M.I.A . . . 4

1.2.1 Práce s AI . . . 4

1.2.2 Lokální spuštění . . . 4

1.3 Motivace k projektu . . . 5

1.3.1 ChatGPT . . . 5

1.3.2 Vlastní kreativita a inovace . . . 5

2 Specifikace projektu – Akva **6**

3 Úvod do problematiky a použité technologie **7**

3.1 Generace odpovědi – text . . . 7

3.1.1 Hlavní LLM . . . 7

3.1.2 Classifier . . . 7

3.1.3 Přídavné moduly . . . 8

3.1.4 Tvorba finálního promptu . . . 8

3.2 Generace odpovědi – obrázek . . . 9

3.2.1 Stable Diffusion . . . 9

3.2.2 Prompt pro obrázek . . . 10

3.3 Komunikace . . . 10

3.3.1 Mluvený projev . . . 10

3.3.2 Platforma . . . 10

4 Implementace samotného projektu **11**

4.1 Generace textu . . . 11

4.1.1 Hlavní LLM . . . 11

4.1.2 Classifier . . . 11

4.1.3 Vektorová databáze a paměť . . . 11

4.1.4 Google kalendář . . . 12

4.2 Generace obrázku . . . 12

4.2.1 Stable Diffusion . . . 12

4.2.2 LoRA . . . 12

4.3 Komunikace s Asistentem . . . 12

4.3.1 Emotion Classifier a samolepky . . . 12

4.3.2 Text-to-speech . . . 13

4.3.3 Speech-to-text . . . 13

4.3.4 Telegram . . . 13

4.4 Konečná verze Asistenta . . . 13

4.5 Další funkce plánované do budoucnosti . . . 14

5 Problémy a jejich řešení **15**
5.1 Problémy týkající se práce s AI 15
5.1.1 Hardware limitace 15
5.1.2 Dlouhá odezva 15
5.1.3 LLM 15
5.2 Řešení problémů 15

6 Závěr **16**
6.1 Budoucnost projektu 16

7 Zdroje **17**
7.1 Github repo 17

1 Úvod

V úvodu práce se zaměřím především na to, jak projekt M.I.A vznikl a co vůbec projekt M.I.A je. Proč jsem si takový projekt vůbec vybral a co mě k němu vedlo. V další části představím svou hlavní část projektu a všechny její funkce i s její implementací. Na závěr se rozepíšu i o problémech, které při práci na projektu nastaly a zmíním se také mé současné a budoucí cíle s projektem.

1.1 Co je Projekt M.I.A?

M.I.A neboli Mišíkovi Interaktivní Asistenti je můj osobní projekt, který se zaměřuje především na práci s umělou inteligencí a využití velkých jazykových modelů(tzv. LLMs) pro osobní využití a každodenní život. Jedná se o sadu AI pomocníků, kteří mají za úkol usnadnit některé repetitivní každodenní úkoly, jako je například používání kalendáře pro zjištění vašich plánu na konkrétní den, nebo obohatit vaše zpěvácké dovednosti, když nejste úplně nejlepší zpěvák. Hlavní hvězdou celého projektu je **Akva**, o které se postupně v dalších částech dokumentace dozvíte více.

1.2 Vznik a Cíl Projektu M.I.A

1.2.1 Práce s AI

Hlavním cílem projektu bylo, naučit se s umělou inteligencí pracovat a zjistit, jak vlastně funguje. Co vlastně práce s umělou inteligencí obnáší a jaké jsou možnosti jejího využití v dnešní době. I když tento cíl je spíše osobní a není přímo spojen se samotnými Asistenty, je pro mě tím nejdůležitějším, neboť si myslím, že umělá inteligence tady s námi bude ještě dlouho a její vývoj postupně změní svět kolem nás.

1.2.2 Lokální spuštění

Dalším cílem, který se už týká i samotných Asistentů, je možnost lokálního spuštění. Osobně nejsem zrovna milovník měsíčních předplatných a bohužel u umělé inteligence jich je dnes spousta. Proto celý můj projekt je zaměřen na využívání pouze Open Source modelů a věci, které si zdarma můžete najít nebo stáhnout.

1.3 Motivace k projektu

1.3.1 ChatGPT

Samostatná motivace k tomu, vytvořit si nějakého Chatbota nebo Asistenta vznikla samozřejmě při vydání ChatGPT. Už v té době jsem byl fascinován tím, že program zvládá odpovídat na mé dotazy a můžu s ním vést konverzaci. Vytvořit si něco takového doma a *zdarma* bylo to, co mě donutilo se o umělou inteligenci více zajímat.

1.3.2 Vlastní kreativita a inovace

V době, kdy ChatGPT začínalo, se jednalo pouze o chatovacího bota, který odpověděl pouze v textové formě, nic víc, nic míň. Dnes Chatboti dokáží nakreslit obrázek, shrnout video či PDF dokument v několika odstavcích. *Neubudu se divit, když za pár let vám u toho udělá i kávu.* Vývoj v oblasti umělé inteligence je tedy pro mě velkou motivací zlepšovat nejen své Asistenty, aby pokročily s dobou, ale i sebe.

2 Specifikace projektu – Akva

Akva je více modelová umělá inteligence, která zvládá odpovídat jak v textové/hlasové formě, tak i pomocí obrázků. Její silnou stránkou je, že uživatel má velkou kontrolu nad jejím charakterem, který je jednoduše přepsatelný a pozměnitelný. Akva nezaostává ani v ostatních funkcích, které jsou v dnešní době považované za nutnost. Zvládne říci jaké je dnes počasí nebo jaké plány máte na zítřek připravené. Zvládne nakreslit obrázek o který je požádaná a narozdíl od jiných Chatbotů ví, jak vlastně vypadá, tudíž umí poslat i selfie jak hraje na kytaru. Další funkce, kterou Akva disponuje, je komunikace pomocí hlasu. Akva zvládne, jak přijmout dotaz pomocí hlasové zprávy a zároveň na ní svým hlasem odpovědět. Komunikuje především přes Telegram, ale do budoucna také bude možné s ní chatovat přes Discord.

Jedná se tedy o plnohodnotného nastavitelného Asistenta, který pomůže s leckterým problémem. Funkcemi a možnostmi se vyrovná Chatbotům a Asistentům od velkých firem, jako je například Chatbot Copilot od Microsoftu nebo Asistent Alexa od Amazonu. Oproti ostatním je také OpenSource a nemusíte za nic platit. *Teda kromě elektřiny.*

3 Úvod do problematiky a použité technologie

V této části dokumentace se seznámíme se třemi částmi celého projektu, ze kterých se konečný program skládá. První část se zabývá textové generaci odpovědi, Druhá naopak generaci obrázku. V té poslední se zaměřím na samostatnou komunikaci s Akvou. U každé části budou jednotlivě popsány, co v programu dělají a k čemu slouží a proč tam vůbec jsou.

3.1 Generace odpovědi – text

Generace textové odpovědi je nejdůležitější část celého projektu, neboť bez toho žádný Chatbot nebo Asistent existovat nemůže. Také se jedná o velkou výzvu, aby vygenerovaná odpověď byla použitelná a pochopitelná.

3.1.1 Hlavní LLM

alfa a omega celé textové generace je velký jazykový model. LLM jsou natrénovány tak, aby rozuměli lidské řeči, ale i přesto s nimi není jednoduché pracovat. Jedná se miliardovou skupinku proměnných, které spolupracují a jsou navzájem propojené a je naším úkolem, abychom jim dali dostatečné množství kontextu a informací k tomu, aby nám vytvořily použitelný výstup.

Dnes najdete LLM k vyzkoušení téměř všude. Pro vyzkoušení modelů doporučuji stránku HuggingFace, kde najdete všechny různé OpenSource modely zdarma ke stáhnutí.

Druhým způsobem je využití API, které slouží k tomu, aby vývojář mohl využívat a měl přístup k nejnovějším LLM od velkých firem a nemusel být závislý na svém vlastním hardwaru. Jedná o nejjednodušší zapojení silné umělé inteligence do vašeho projektu, bez nutnosti špičkového hardwaru, za pár centů.

Celkově je ale potřeba si udělat svůj vlastní výzkum pro práci s LLM, převážně jestli chcete s nimi pracovat lokálně.

3.1.2 Classifier

Pro vytvoření pravého Asistenta, který není obyčejným Chatbotem, je potřeba, aby zvládal i plnit zadané úkoly. Classifier slouží k tomu, aby při pokynu uživatele rozhodl, co ke své odpovědi bude potřebovat. Classifier je možné zavést několika způsoby, jedním z nich je manuální psaní IF statementů, ale tomu to způsobu bych se vyvaroval.

Druhým způsobem je nechat LLM rozhodnout, co ke splnění úkolu vlastně potřebuje. Tento způsob je více *organický* a také může mile překvapit s odpovědí, kterou jste nečekali. Problémů je ale hned několik. Největšími problémy je nepřesnost a

doba konečné odpovědi. Dotazujeme se totiž na stejnou otázku dvakrát, jednou pro zjištění potřebných modulů a po druhé k při tvorbě odpovědi.

3.1.3 Přídavné moduly

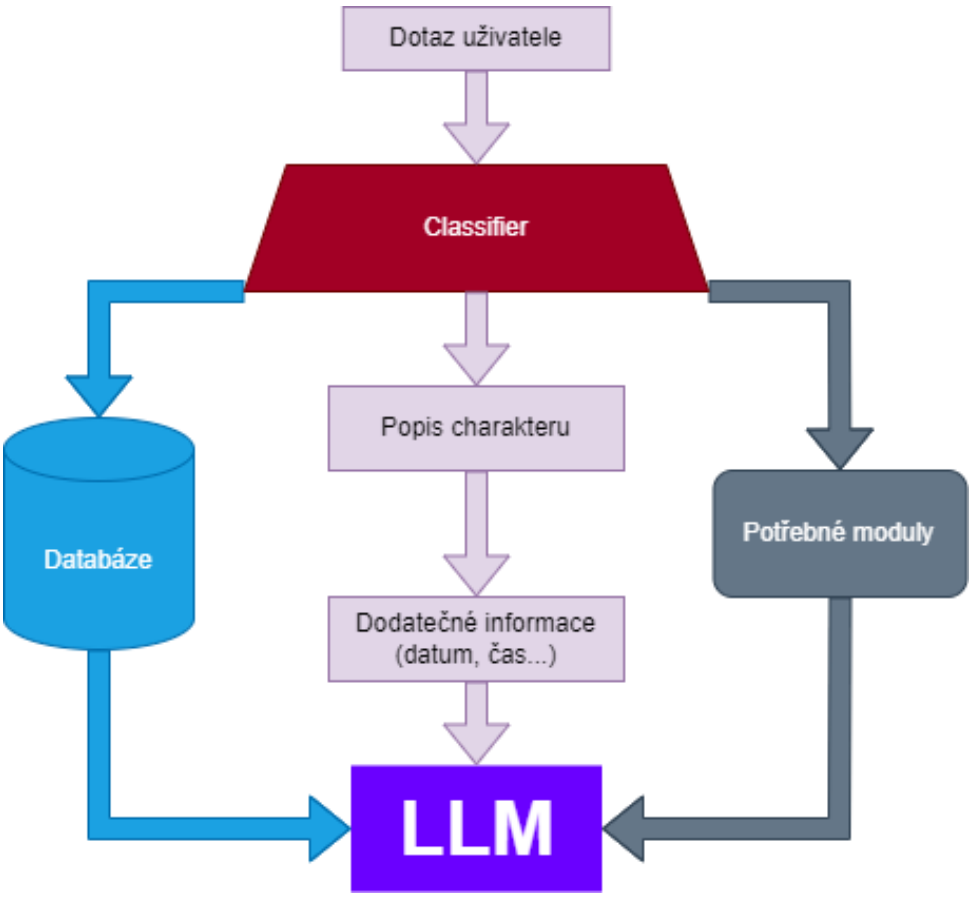
Přídavné moduly slouží k získání potřebných informací k tvorbě správné odpovědi. Dále přidávají nové vlastnosti a funkce, kterými může Asistent disponovat. Jedná se například o krátkodobou a dlouhodobou paměť, přístup ke kalendáři a počasí, nové způsoby komunikace, práce s PDF a generace a poznávání obrázků a mnoho dalších. Je jen na vás, co všechno váš Asistent dokáže.

3.1.4 Tvorba finálního promptu

Samotné LLM nemá žádnou paměť, vědomí ani city, musíme tedy všechny tyto informace modelu nějak předat. K tomu nám poslouží prompt. Ten musíme seskládat tak, aby obsahoval potřebné informace a zároveň nebyl příliš dlouhý, neboť každé LLM má svůj takzvaný "Context limit", do kterého se musíme s promptem vejít. Context limit se odvíjí od velikosti samotného LLM, ale bývá okolo 1-32 tisící tokenů (1000 tokenů = 750 slov).

U Chatbotů jako je ChatGPT nám stačí pouze položit otázku a nemusíme řešit všechny věci okolo, neboť ty se dějí v zákulisí, kde mi nevidíme. U vlastních Chatbotů, především OpenSource jazykových modelů, tvorba srozumitelného promptu dá zabrat a bývá největším oříškem na rozlousknutí. Tomuto problému ani nepřidává to, že každé LLM je jinak trénované. Při tvorbě promptu se musíme tedy přizpůsobit stylu jakým byl trénován.

Na další stránce je diagram, jak by takový finální prompt, pro generaci textu, mohl vypadat a z jakých částí se skládá



Obrázek 1: Diagram textového promptu

3.2 Generace odpovědi – obrázek

Druhou možnou odpovědí je odpověď pomocí obrázku. Generace či tvorba obrázků je velmi podobná jako generace textu. Využíváme LLM, které je specificky trénované na tvorbu obrázků a specifický prompt pro generaci vysněného obrázku.

3.2.1 Stable Diffusion

Stable Diffusion je jedním z nejznámějších a nejpoužívanějších typů modelů převádějící text na obraz. hlavním faktorem je i to, že tento typ modelů je OpenSource a můžete si ho tak sami vyzkoušet.

Stable Diffusion funguje na principu "Difúze"neboli postupného odstraňování šumu, který není tak náročný na matematické výpočty. V praxi to znamená, že nepotřebujete obrovský model na tvorbu kvalitních obrázků. I přes technologické pokroky je samostatná generace obrazku výpočetně náročná.

Stejně jak u textu i zde můžete využít placené API a vyhnout se tak problému s nedostatečným hardwarem

3.2.2 Prompt pro obrázek

Samotný prompt pro obrázek je rozdělen na dvě důležité části, které rozhodují o tom, zda se obrázek povede přesně tak, jak chcete.

První část je "prompt"neboli popsání obrázku, který chcete vygenerovat. Zde říkáte vše, co vlastně po obrázku chcete. Může se jednat o popis červeného auta nebo něčeho konkrétnějšího. Dále zde popisujete i kvalitu obrázku, pozadí, osvětlení a jiné prvky, které chcete ať obrázek obsahuje.

Druhá část je zaměřena právě na to, co v obrázku nechcete, takzvaný "negative prompt". Zde píšete vše, co vás napadne ohledně špatně vytvořeného obrázku. Tím může být například špatná kvalita, pixelový, zamazaný obrázek nebo jestli hodláte generovat lidi, tak zde napíšete, ať daný člověk nemá více prstů na rukou.

Jelikož je opravdu spousta věcí, které se při generaci chcete vyhnout. Lidé vymysleli takzvané "embeddings"přímo pro Stable Diffusion modely. Embedding v této situaci je vnořené slovo. Jedná se o vzájemné spojení několika různých slov do jednoho, kterému model rozumí. Uživatel poté nemusí vypisovat desítky negativních promptů, ale stačí mu jeden nebo dva, které obsahují všechny nechtěné vlastnosti.

3.3 Komunikace

K čemu by byl Chatbot bez možnosti s ním chatovat. Poslední částí je samozřejmě najít způsob, jak s LLM komunikovat. Psaní pomocí textové formy je fajn, ale po nějaké době to začne být nuda. Je tedy nutné najít způsob, jak Chatbotovi umožnit sdílet své emoce a pocity.

3.3.1 Mluvený projev

První možnost je dát Chatbotovi vlastní hlas. K tomuto využijeme **text-to-speech**. Existuje několik text-to-speech programů, které můžeme využít, ale většina z nich je placená nebo se jedná o obyčejné hlasy, které slyšíme například z Google překladače.

Další možností je využít TTS zaměřený model a vytrénovat si svůj vlastní hlas, který rádi posloucháte.

3.3.2 Platforma

Poslední věcí, která je třeba vyřešit, je platforma, na které s Chatbotem komunikovat. Musí se jednat o platformu, která povoluje nejen textovou a obrázkovou formu, ale i hlasovou stopu. Naštěstí možností je hned několik. Některé však nepovolují mít vlastního bota a je tedy potřeba některé věci obejít.

4 Implementace samotného projektu

V této kapitole budu více konkrétnější. Zaměřím se na řešení jednotlivých problémů v mém projektu a přiblížím jednotlivé kroky, které vedly k finální verzi mého Asistenta.

4.1 Generace textu

4.1.1 Hlavní LLM

Jakožto hlavní LLM pro můj projekt jsem si vybral OpenSource model od společnosti Meta s názvem Llama 2.gguf. Typ modelu GGUF využívám proto, protože je schopný generovat tokeny pomocí procesoru i grafické karty. Program je tedy flexibilnější na hardware a je schopný využívat více modelů, které jsou schopné pracovat pouze na grafické kartě (generace obrázků). Pro práci s modelem v Pythonu využívám knihovnu llama.cpp, která práci s jazykovým modelem umožňuje a zjednodušuje.

4.1.2 Classifier

Rozhodování o potřebných přídavných modulech jsem prozatím nechal na hlavním LLM. Do budoucna, až všechny moduly budou hotové a budu schopný si vytvořit potřebná data k tréninku, plánuji vytrénovat vlastní malý model, který tuto funkci bude vykonávat.

4.1.3 Vektorová databáze a paměť

Jak jsem zmiňoval dříve. Jazykové modely nemají svojí vlastní paměť a je tedy potřeba se o ní postarat. Můj Asistent využívá dva typy paměti. Krátkodobou a dlouhodobou.

Krátkodobá paměť slouží k orientaci LLM v současné konverzaci. Konverzace se zapisuje do textového souboru, který je pak posílán zpátky do konečného promptu. Součástí je tokenizační model, který kontroluje celkovou délku konverzace v tokenech (kvůli Context-limitu LLM). Při vypnutí a zapnutí programu, se celá konverzace smaže a vytvoří se nová.

Dlouhodobá paměť je o něco zajímavější. Využívám k ní lokální vektorovou databázi, kterou jsem vytvořil pomocí knihovny HyperDB. Do vektorové databáze ukládám všechny konverzace ve vektorové formě. O konverzi textu na vektory se stará OpenSource embedding model. Vektorová forma je pro komunikaci s databází velmi výhodná, neboť jednotlivé vektory umí počítač velmi dobře porovnávat a najít tak podobné vektory, které následně využívám ve tvorbě promptu. Při každém uživatelském vstupu dojde k porovnání vektorů uložených v databázi a vektoru vy-

tvořeného z uživatelského vstupu. Dva nejvíce podobné vektory v textové formě se vypíšou do konečného promptu a dochází tak k efektu, kdy si LLM vybaví věci, které nastaly dávno v minulosti.

4.1.4 Google kalendář

Google kalendář je funkce vytvořená k tomu, abych se sám nemusel dívat do kalendáře. Při dotazu na událost nebo na určitý den, se spustí funkce, která pomocí Google Calendar API sebere všechny potřebná data z mého kalendáře a následně je vypíše do konečného promptu.

4.2 Generace obrázku

4.2.1 Stable Diffusion

Největší výzvou u generace obrázků bylo najít model, které je schopné zvládnout velké množství kontextu. Nakonec jsem skončil u Stable Diffusion modelu od StabilityAI. S modelem pracuji pomocí knihovny Diffusers a jejich před vytvořené Pipeliny právě pro tento model.

4.2.2 LoRA

Jelikož se jedná o personalizovaného Asistenta bylo by fajn, aby Asistent sám věděl, jak vypadá. K tomu na poslouží LoRA (low-rank adaptation of large language models). LoRA je speciálně vytrénovaný malý model, který při integraci do velkého modelu přidává nové techniky ke zlepšení kvality a přesnosti obrázku. V našem případě při integraci LoRY do promptu můžeme model donutit k tvorbě obrázků se specifickými vlastnostmi, které popisují, jak náš Asistent vypadá.

Pokud si chcete nějaké LoRY při práci se StableDiffusion modelem vyzkoušet, doporučuji se podívat na stránku CivitAI.

4.3 Komunikace s Asistentem

Závěrem bylo vytvořit prostředí kde s Asistentem komunikovat a také mu dát více možností, které může ke svému projevu použít.

4.3.1 Emotion Classifier a samolepky

K projevu emocí využívám Emotion Classifier, což je model, který z jednoduchých vět i souvětí, vyhodnotí emoce, které z textu vyplívají.

Tyto emoce mám poté spojené se samolepkou odpovídající dané emoci. Asistent tedy má tu možnost vyjádřit se i pomocí samolepky, která emočně souvisí s jeho odpovědí.

4.3.2 Text-to-speech

Jakožto Text-to-speech model využívám model od Microsoftu, který povoluje 5 hodin audia zdarma. Poprvé zde tedy ohýbám svůj cíl, mít celého asistenta kompletně zdarma.

Text-to-speech model také využívá Emotion Classifier. K jednotlivé emoci je spojen i typ hlasu, kterým Asistent odpovídá. Asistent je tedy ještě více schopen vyjádřit své city.

4.3.3 Speech-to-text

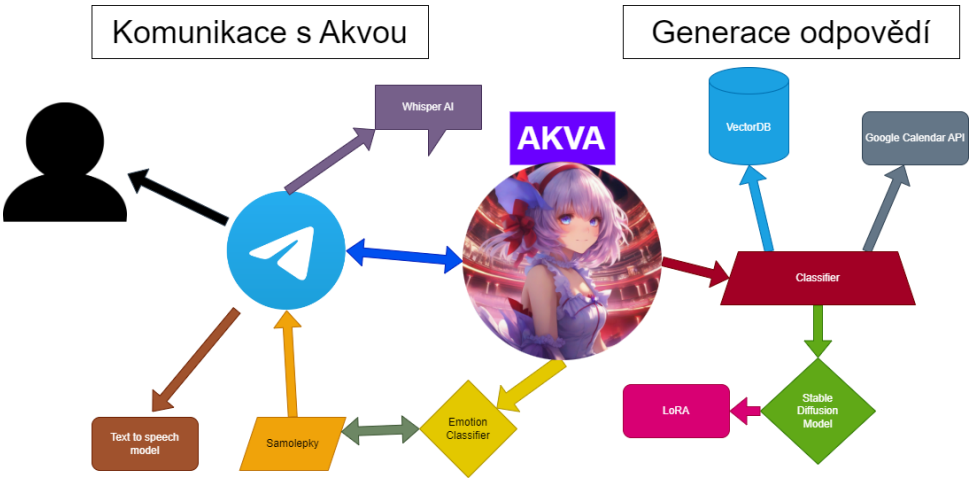
Speech-to-text je jediná funkce, kde používám placené API od OpenAI. Doposud jsem nenašel model, který by byl zdarma a aspoň trochu přesný. Funkce slouží k tomu, aby uživatel mohl nahrát svůj dotaz hlasem.

Funkce se dá kdykoliv a není potřeba jí tedy používat.

4.3.4 Telegram

Pro komunikaci s Asistentem jsem použil Telegram, protože Telegram narozdíl od jiných Instant-messanging aplikací povoluje mít vlastního Bota přímo na platformě. Telegram má svou vlastní knihovnu a zdarma API, které jsem v projektu využil.

4.4 Konečná verze Asistenta



Obrázek 2: Diagram konečného Asistenta

4.5 Další funkce plánované do budoucnosti

Do budoucna bych rád přidal i některé další funkce a moduly. Jedním z nich je například modul týkající se předpovědi počasí. Rád bych přidal i možnost pracovat s PDF soubory a využít tak vektorovou databázi naplno. Bohužel zde je problém s malým Context-limitem používaného LLM.

Další zajímavou funkcí by mohlo být rozeznávání obrázků a začínání konverzace. Prozatím jsem na tyto funkce výzkum nedělal a je potřeba nejdříve vyřešit některé problémy, než se pustím do nových funkcí.

Poslední věc, na kterou bych se chtěl do budoucna podívat je funkčnost na jiných platformách, než je Telegram. Rád bych vyzkoušel propojení například s Discordem nebo Messengerem.

5 Problémy a jejich řešení

5.1 Problémy týkající se práce s AI

Vždy se nějaké problémy najdou a ani můj projekt není výjimkou, rád bych zmínil pár nejdůležitějších problému, se kterými jsem se setkal.

5.1.1 Hardware limitace

Hardware je a bude největším problémem umělé inteligence, jak pro multimilionové firmy, tak i pro jedince, kteří s umělou inteligencí chtějí pracovat. Jelikož jsem se vydal cestou nepoužívat placené API od OpenAI musel jsem projekt přizpůsobit ke svému stolnímu počítači a získat z něj co nejvíc co to jde. Bohužel některé funkce Asistenta jsou spustitelné pouze, pokud je jiná funkce vypnutá. Některé z nich museli být odloženy na dobu neurčitou.

5.1.2 Dlouhá odezva

Součástí problému s hardwarem je i celková doba odpovědi. Kvůli nedostatečné velikosti paměti v grafické kartě, kterou používám na generaci obrázků, jsem nucen využívat procesor ke generaci textu. Procesor neumí pracovat na více věcech najednou narozdíl od grafické karty, která pracuje paralelně. Celková doba odpovědí tak může trvat i minutu (obrázek i 2-3 minuty)

5.1.3 LLM

Samostatné LLM, které v projektu používám, je přes rok staré a s tím, jak se technologie posunula dopředu, můžu tento jazykový model považovat za dědečka. Občas se tedy stane, že odpověď přijde jiná, než se čekalo.

5.2 Řešení problémů

Naštěstí je spousta problému, které se dají vyřešit. Problém s odezvou a hardwarem by vyřešilo použití placeného API, ale kvůli povaze projektu a jeho cílům bych se této možnosti rád vyhnul. Pořízení lepší výpočetní techniky je otázka budoucnosti.

Výměna LLM za novější verzi je možnost, která by s generací mohla pomoci. Znamenala by ale úpravu většiny promptů pro generaci textových odpovědí.

Jiný jazykový model –> jiná trénovací data –> jiný styl promptu

6 Závěr

S projektem jsem začínal v červnu 2023 kompletně bez znalostí umělé inteligence a téměř bez znalostí programování v Pythonu. Za necelý rok jsem se dozvěděl spoustu věcí o umělé inteligenci a celkové úpravě psaného kódu. Zjistil jsem také, že je stále co se učit. Umělá inteligence se neustále vyvíjí a je tedy pořád něco nového, v čem je potřeba se zlepšit.

6.1 Budoucnost projektu

V projektu budu i nadále pokračovat, získávat zkušenosti a znalosti ohledné umělé inteligence, neboť s tím, jak rostu já a zlepšuji se jako programátor, zlepšují se i moji Asistenti.

V celém projektu se nadále budu snažit vyhýbat placeným API nebo Cloudovým serverům. Výhodou je, že nejsem závislý na multimilionových firmách a jejich modelech a mám tak větší paletu modelů, ze které si mohu vybrat. I přes některé hardwarové limitace jsem motivovaný i nadále pracovat na mém vlastním počítači a dokázat si, že i bez využívání placených předplatných je možné vytvořit něco, co aspoň trochu funguje.

7 Zdroje

Většina použitých zdrojů se nachází už v konkrétních částech dokumentu, zde bych chtěl přidat ty více obecnější zdroje od kterých jsem se inspiroval.

Youtube video, které mě inspirovalo si něco podobného vytvořit

Discord server kolem umělé inteligence

7.1 Github repo

Zde je odkaz na zdrojový kód a případně mé další budoucí projekty: Akva AI